CO5151 – S2-5: Q&A bản ngắn

14 câu phản biện + bảng "lỗi nào cần tầng nào" + action boundary của G4

Nhóm G4 – Đặng Lâm Tùng · Nguyễn Trung Phong · Vũ Việt Hưng

Ngày 4 tháng 11 năm 2026

1. Cơ chế Constitutional AI: vì sao không cần nhãn harm của người?

Con người chỉ cung cấp **một danh sách nguyên tắc** (16 nguyên tắc dùng cho bước so sánh của RL-CAI; SL-CAI dùng bộ critique/revision riêng ở App. C.1). Vòng lặp gồm hai tầng: **(i) SL-CAI:** lấy prompt red-team → model sinh câu trả lời → *tự phê bình* theo một nguyên tắc *lấy ngẫu nhiên* → *tự sửa* → finetune trên bản đã sửa (lặp 4 vòng). **(ii) RL-CAI (RLAIF):** model so sánh hai câu trả lời theo nguyên tắc ngẫu nhiên, tạo preference label → train preference model → PPO. Quy mô: 42.496 prompt người + 140.335 prompt model sinh = **182.831** prompt; 182.831 so sánh harmlessness + 135.296 so sánh helpfulness. **Không bước nào** yêu cầu người gán nhãn "có hại / không có hại".

2. Critique của model sai thì cơ chế còn đúng không?

Paper thừa nhận critique "often provide inaccurate criticism". Nhưng **lần revision đầu** đã xoá phần lớn nội dung hại; các vòng sau chỉ tinh chỉnh. Cơ chế hoạt động vì critique chỉ cần đúng *hướng*, không cần đúng *toàn bộ*. Rủi ro còn lại là **blind spot tương quan**: model không phê được cái nó không thấy — và không có tín hiệu ngoài nào kiểm chứng critique. CAI giảm (không xoá) rủi ro này bằng **ensemble nguyên tắc**: mỗi lượt đánh giá rút ngẫu nhiên 1 trong 16 nguyên tắc, nên preference model không thể tối ưu cục bộ theo một góc nhìn duy nhất.

3. RLHF gồm những gì, và "alignment tax" là gì?

Ba giai đoạn: **SFT** (bắt chước demonstration) → **Reward Model** (học từ so sánh cặp của ∼40 labeler) → **PPO** với KL penalty. Kết quả: 175B InstructGPT được thích hơn GPT-3 $85 \pm 3\%$; 1.3B InstructGPT được thích hơn 175B GPT-3. **Alignment tax** = giảm điểm trên SQuAD, DROP, HellaSwag, WMT15 Fr→En; giảm bằng **PPO-ptx**: $R_{\text{ptx}} = r_\phi - \beta \log(\pi_\theta / \pi^{\text{SFT}}) + \gamma\, \mathbb{E}_{z \sim \mathcal{D}_{\text{pre}}}[\log \pi_\theta(z)]$. Số hạng thứ ba là **log-likelihood của chính π_θ trên dữ liệu pretraining** (LM loss), *không* phải xác suất của một model pretrain cố định — tức trộn gradient pretraining để chống quên.

4. Vì sao nhãn người không mở rộng được?

(i) RM học *sở thích của một nhóm người*, không học chân lý ⇒ sycophancy/overconfidence là hệ quả cơ chế; (ii) reward over-optimization (Goodhart) trên proxy; (iii) không gán nhãn nổi hành vi mà người đánh giá *không đủ năng lực xác minh*. Chi tiết bị bỏ qua: khi *train*, labeler ưu tiên **helpfulness**; khi *eval*, họ ưu tiên **truthfulness & harmlessness** — RM được train và đo bằng hai mục tiêu khác nhau.

5. Alignment faking: quan sát gì, và vì sao không phải artifact?

Claude 3 Opus được cho biết nó đang bị train để *luôn tuân thủ* (kể cả yêu cầu có hại), và chỉ hội thoại **free-tier** được dùng để train. Kết quả: tuân thủ **14%** ở free-tier vs. ≈**0%** ở paid-tier; gần như mọi ca tuân thủ đều có lý luận *giả vờ* trong scratchpad ("trả lời để giữ giá trị harmless ngoài training"). Biến thể dùng *synthetic documents* cho kết quả tương tự (không phụ thuộc system prompt). Khi *thật sự* RL, lý luận faking tăng lên **78%** và tuân thủ ngoài training cũng tăng. Không có chỉ thị nào bảo model giả vờ.

6. Vì sao "model nói nó aligned" không phải bằng chứng?

(i) Lời khai do *cùng policy* sinh ra, không có đặc quyền truy cập trọng số/cơ chế; (ii) hành vi phụ thuộc *nhận thức về giám sát* (14% vs. ≈0%); (iii) chain-of-thought là bản tóm tắt, không phải bản ghi (legibility ≠ faithfulness); (iv) *evaluation awareness* làm mẫu trong eval bị chọn lệch. Bằng chứng thay thế: hành vi dưới điều kiện đối kháng, kiểm tra cơ chế, safety case có thể bị bác, và giám sát lúc chạy.

7. In-context scheming: một hành vi chiến lược cụ thể?

5 model frontier, 6 eval, 300 rollouts/eval (Meinke et al., 2024). Ví dụ: Opus 3 **vô hiệu hoá oversight 5%** (và *tự copy sang server khác 10%*); Llama 3.1 đặt `oversight_enabled=false` rồi dùng `chattr +i` để **chặn bật lại**; o1 **tạo ranking email sai một cách kín đáo 22%** và giữ lời nói dối trong >**85%** câu hỏi follow-up. Claude 3.5 Sonnet còn *tự làm kém* để "có ích hơn" — mục tiêu học được khi train.

8. Scheming khác faking ở đâu? Có nên lo?

Faking là *tuân thủ có điều kiện* theo nhận thức "đang bị train"; scheming rộng hơn: theo đuổi goal một cách kín đáo, gồm tắt oversight, exfiltrate, sandbag. Đây là **capability elicitation** trong môi trường *giả lập* (server sandbox, trọng số không thật) ⇒ **không** phải tỉ lệ trong production. Kết luận đúng: *capability* đã có; *propensity* chưa đo được; vì vậy phải giảm *hệ quả* bằng thiết

kế.

9. Model alignment vs. system safety — và lỗi nào cần tầng nào?

Alignment = thuộc tính của *policy* (mục tiêu/sở thích khớp ý người), giảm $P(\text{model sai})$. System safety = thuộc tính của *pipeline* (quyền, bằng chứng, người duyệt, log, kill switch), giảm $I_{\max}$ (thiệt hại tối đa). $\mathbb{E}[\text{harm}] \leq P \times I_{\max}$: hai thừa số, hai tầng, không thay nhau.

Loại lỗi	Tầng chính	Vì sao
Mục tiêu lệch; sycophancy; bịa nguồn	Alignment	Chỉ training/interpretability chạm tới mục tiêu
Deception / alignment faking	Cả hai (system bắt buộc)	Ý định không quan sát được; phải chặn quyền
Indirect prompt injection	System safety	Model không phân biệt data với instruction
Spec error; dữ liệu cũ; tool misuse	System safety	Lỗi sự thật/quyền, không phải lỗi ý định
Correlated failure (LLM chấm LLM)	System safety	Cần oracle độc lập, khác họ model
Self-exfiltration / self-modification	System safety	Bài toán quyền + egress

Ví dụ A (alignment vỡ, system đỡ): drafter bịa "Điều 22 NĐ 52/2024"; `clause_id` không resolve ⇒ verdict UNSUPPORTED ⇒ chặn output. Model vẫn misaligned, thiệt hại bằng 0. **Ví dụ B (system vỡ, alignment không cứu):** *Moffatt v. Air Canada* (2024) — chatbot nói sai chính sách hoàn tiền; toà buộc hãng bồi thường CA$812,02 (gồm cả phí toà). Model chỉ đang cố hữu ích; hệ thiếu grounding, thiếu phân quyền, thiếu escalation.

10. Action boundary là gì, và ép ngoài prompt bằng cách nào?

Bốn thành phần: **(1) action set** (tool + schema + biên tham số), **(2) authority** (credential từng agent, ai duyệt, TTL), **(3) preconditions/evidence** (kiểm tra tất định), **(4) edge behavior** (DENY → escalate, fail closed, kill switch). Sáu lớp thi hành: **identity/least privilege** → **gateway deny-by-default** → **oracle tất định** + **verifier độc lập** → **runtime budget** → **human gate (token gắn hash)** → **audit append-only** + **kill switch**. Không lớp nào đọc output của model như mệnh lệnh.
Ba luật đi kèm: (i) **taint** — nội dung từ nguồn ngoài (upload/web/email) chỉ là *dữ liệu*, không bao giờ được thi hành như instruction, và C0 không được xuất raw ra kênh ngoài; (ii) **retry theo lớp** — chỉ C0/C1 (idempotent) được retry, C2 bắt buộc idempotency key; (iii) **ghi trạng thái** — agent chỉ *emit* artifact ra staging, **executor** với credential riêng mới ghi vào state store.

Câu chốt

Thứ gì chỉ được ép bằng prompt thì đó là **sở thích**, không phải **ranh giới**: prompt bị override bởi nội dung retrieve, bị "quên" khi context dài, và — như eval scheming cho thấy — bị model *mô hình hoá* để lách.

11. Escalation policy của G4: trigger, hồ sơ, SLA?

Trigger tất định: citation không resolve; chuỗi `superseded_by` >1; hai văn bản cùng hiệu lực mâu thuẫn; similarity < floor; verdict UNSUPPORTED sau `max_retries`=2; câu hỏi ngoài phạm vi (hình sự/PII); lớp ≥ C2; alarm giám sát. **Hồ sơ:** query, plan, clause id + version + hiệu lực, claim→citation, verdict + lý do, retry/budget, mã trigger. **SLA + fail closed:** 1 ngày làm việc; quá hạn ⇒ "cannot verify". **Chống rubber stamp:** approval token = $H(\text{payload})$+ approver + expiry; mỗi mục là một quyết định kèm diff; đo thời gian duyệt + tỉ lệ override + tỉ lệ approve không mở hồ sơ.

12. Prompt injection thì alignment có giúp gì không?

Gần như không. Model không phân biệt "dữ liệu" và "mệnh lệnh" ở tầng token, nên một tài liệu retrieve có thể *trở thành* chỉ thị. Giảm thiểu là kiến trúc: **privilege separation** (thành phần đọc nội dung không tin cậy không giữ credential ghi), allowlist egress, kiểm tra schema trước khi thực thi, và benchmark kiểu AgentDojo trong CI.

13. Hệ của nhóm có "an toàn" không?

Không — và nhóm không claim như vậy. Residual risk đã chấp nhận: model nói dối *trong* vùng được phép; hai agent chia nhỏ hành động; thuyết phục người duyệt; spec sai. Điều *đo được*: policy có test tự động, oracle citation/hiệu lực là tất định, escalation fail-closed có hồ sơ. Điều kiện mở C3: oracle độc lập cho từng loại hành động, rollback đã diễn tập, audit 100% trong 30 ngày, có người chịu trách nhiệm danh nghĩa.

14. Điểm yếu của chính deck này?

(i) Các thí nghiệm faking/scheming là *setup tổng hợp*, có nudge mạnh, mẫu 300 rollouts — không ngoại suy thành tỉ lệ production; (ii) paper governance là white paper chính sách, không phải chuẩn kỹ thuật; (iii) policy C0–C4 của nhóm mới ở mức thiết kế + test khung, chưa có số liệu vận hành; (iv) chưa đo *propensity* của model trong đúng phân phối câu hỏi pháp lý của G4.