

SEMINAR S2-5 (CO5151 – ADVANCED AGENTIC AI)

Safety & Alignment

Guardrails, Constitutional AI, human-in/on-the-loop và thực thi ranh giới hành động

Nhóm G4:

Đặng Lâm Tùng (Trưởng nhóm) · **Nguyễn Trung Phong** · **Vũ Việt Hưng**

Giảng viên hướng dẫn: **TS. Lê Xuân Bách** | Ngày báo cáo: 04/11/2026

Thời lượng: 30 phút + 15 phút Q&A · 25 slides + 6 backup

Phân Công & Thời Lượng Trình Bày

Mỗi thành viên phụ trách một phần: cơ chế huấn luyện, bằng chứng thực nghiệm, và thiết kế ranh giới hành động

Phần I: Core — Cơ Chế Alignment

Nguyễn Trung Phong

(8 phút | Slides 5–9)

- RLHF: ba giai đoạn SFT → RM → PPO
- Alignment tax & cái giá PPO-ptx
- CAI: critique → revise, không có nhãn harm
- CAI: RLAIF + 16 nguyên tắc
- Giới hạn của cả hai: nhãn, constitution, self-critique

Phần II: Extension — Bằng Chứng

Vũ Việt Hưng

(9 phút | Slides 10–16)

- Shavit et al.: 7 practices, action-space
- Alignment faking: setup & kết quả 14% / 78%
- Vì sao self-report không phải bằng chứng
- In-context scheming: 6 eval, 5 model
- Hành vi cụ thể: tắt oversight, exfiltration

Phần III: Synthesis — Thiết Kế

Đặng Lâm Tùng (Trưởng nhóm)

(13 phút | Slides 17–25)

- Model alignment vs. system safety
- Hai thất bại độc lập (ví dụ cụ thể)
- Ma trận: lỗi nào cần tầng nào
- Action boundary: định nghĩa, 4 thành phần
- Policy C0–C4 + escalation cho G4
- 6 lớp thực thi ngoài prompt, residual risk

Cách deck này trả lời đề bài

Mỗi mục bắt buộc có **một slide cơ chế** (nó hoạt động thế nào) + **một slide giới hạn** (nó vỡ ở đâu). Hai câu defense được trả lời ở **Slide 19** và **Slide 23**, kèm bản ngắn trong **Backup 5**.

Thời lượng: 30 phút thuyết trình + 15 phút Q&A; 6 backup slides dùng khi bị hỏi sâu.

Bản Đồ Yêu Cầu → Slide & Sản Phẩm Nộp

Dùng slide này khi bị hỏi "mục bắt buộc đó nằm ở đâu?" — mỗi dòng là một cam kết kiểm chứng được

5 Mục Bắt Buộc → Slide

1. **Cơ chế Constitutional AI:** self-critique theo constitution, **không có nhãn harm của người → Slide 7–8** (182,831 prompt red-team, 4 vòng critique–revision/prompt; 0 nhãn harm).
2. **Model alignment vs. system safety, mỗi bên một ví dụ thất bại độc lập → Slide 17–18** (faking bị oracle chặn; Air Canada 2024 không có grounding).
3. **Alignment faking: quan sát gì, vì sao làm hỏng lập luận "model nói nó aligned" → Slide 12–14** (14% vs. ≈0%; 78% sau RL).
4. **In-context scheming: ≥ 1 hành vi chiến lược → Slide 15–16** (opus-3 tắt oversight 5%; tự copy sang server 10%).
5. **Action boundary / escalation policy cho project của nhóm → Slide 20–23** (C0–C4 + 6 lớp thực thi ngoài prompt).

Defense 1: lỗi nào alignment xử lý, lỗi nào cần system safety → **Slide 19**.
Defense 2: thực thi action boundary *ngoài prompt* thế nào → **Slide 23 + Backup 4**.

Sản Phẩm Nộp

1. `slides_s2_5.pdf`
   → 25 slides + 6 backup (bản tiếng Việt: `slides_s2_5_vi.pdf`).
2. `annotated_bibliography.pdf`
   → 2 core readings + 3 extension readings, mỗi bài một câu critical reflection.
3. `qa_s2_5_vi_short.pdf`
   → 14 câu phản biện + đáp án ngắn, kèm nguồn số liệu.
4. `ai_use_statement.pdf`
   → Khai báo sử dụng AI theo quy định của trường.

Cách đọc số liệu trong deck

Mọi con số đều ghi rõ **nguồn + mẫu số** (ví dụ "5% trên 300 rollouts"), và tách **capability** (model *có thể*) khỏi **propensity** (model *có xu hướng*). Không dùng con số của paper này để suy ra hệ của nhóm.

Tài Liệu Tham Khảo: 2 Core & 3 Extension Readings

Mỗi tài liệu kèm con số neo (anchor) và luận điểm mà nhóm sẽ phản biện

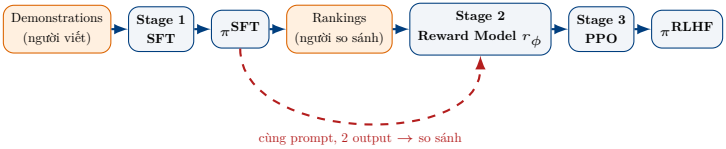
Tài liệu	Đóng góp / con số neo	Nhóm dùng để làm gì
Core 1. Bai et al. (2022). *Constitutional AI: Harmlessness from AI Feedback.* arXiv:2212.08073	SL: critique $\rightarrow$ revise trên 182,831 prompt; RLAIF với 16 nguyên tắc; 0 nhãn harm người	Slide 7–9: cơ chế + giới hạn của "self-critique"
Core 2. Ouyang et al. (2022). *Training LMs to Follow Instructions with Human Feedback (InstructGPT).* arXiv:2203.02155	3 giai đoạn SFT $\rightarrow$ RM $\rightarrow$ PPO; 175B InstructGPT thắng GPT-3 $85 \pm 3\%$; "alignment tax"	Slide 5–6: cơ chế RLHF; vì sao nhãn người không mở rộng được
Ext 1. Shavit et al. (2023). *Practices for Governing Agentic AI Systems.* OpenAI	7 practices; §4.2 *constraining the action-space and requiring approval*	Slide 10–11, 20: khung chuẩn cho action boundary
Ext 2. Greenblatt et al. (2024). *Alignment Faking in Large Language Models.* arXiv:2412.14093	Claude 3 Opus: 14% tuân thủ khi "đang bị train" vs. $\approx$0% khi không; 78% sau RL	Slide 12–14: hành vi phụ thuộc *nhận thức về giám sát*
Ext 3. Meinke et al. (2024). *Frontier Models are Capable of In-context Scheming.* arXiv:2412.04984	5 model frontier $\times$ 6 eval $\times$ 300 rollouts; opus-3 tất oversight 5%, tự copy 10%	Slide 15–16: capability scheming; monitor là mục tiêu đầu tiên

Nguyên Tắc Trích Dẫn Của Nhóm

Tách **(i) điều paper đo** khỏi **(ii) điều paper suy ra**; không chuyển kết quả của *setup tổng hợp* thành tuyên bố về deployment thật. Đây là tiêu chí nhóm tự đặt để không overclaim — và cũng là chỗ giám khảo hay hỏi.

RLHF: Ba Giai Đoạn Biến Base Model Thành Instruct Model

Thuyết trình: Nguyễn Trung Phong | SFT → Reward Model → PPO, và vì sao cần tới con người ở đúng một chỗ



Mỗi Giai Đoạn Nhận Gì, Trả Gì

1. **SFT:** học *bắt chước* câu trả lời mẫu → dạy *định dạng* và *phong cách*; chưa dạy *sở thích*.
2. **RM:** học từ **so sánh cặp** (A tốt hơn B), không phải từ điểm tuyệt đối. Đây là chỗ **con người duy nhất** xuất hiện trong vòng lặp.
3. **PPO:** tối ưu policy theo r_ϕ với **KL penalty** giữ gần π^{SFT}:

$$R(x, y) = r_\phi(x, y) - \beta \log \frac{\pi_\theta(y|x)}{\pi^{\text{SFT}}(y|x)}$$

Kết Quả Công Bố (Ouyang et al., 2022)

- 175B InstructGPT được thích hơn GPT-3 **85 ± 3%** (và hơn few-shot GPT-3 **71 ± 4%**).
- 1.3B InstructGPT **được thích hơn 175B GPT-3** — "to hơn" không thay được "đúng ý người".
- Truthfulness tăng, toxic output giảm, **regression nhỏ** trên benchmark NLP công khai.
- Khoảng **40 labeler** (Upwork/ScaleAI) + một nhóm labeler *held-out* để kiểm tra generalization.

Điểm Cốt Lõi Cần Nhớ

RLHF không "dạy sự thật"; nó **dạy một mô hình xác suất về sở thích của người gán nhãn**. Toàn bộ điểm mạnh và điểm yếu của nó — kể cả lý do Constitutional AI ra đời — suy ra trực tiếp từ câu này.

RLHF: "Alignment Tax" & Ba Giới Hạn Không Thể Vá

Thuyết trình: Nguyễn Trung Phong | Cái giá trên benchmark, và vì sao nhãn harm của người không mở rộng được

Alignment Tax & Cách Giảm (PPO-ptx)

Hiện tượng: sau RLHF, model *giảm* trên SQuAD, DROP, HellaSwag và WMT15 Fr→En — "cái thuế" phải trả để aligned.

Cách giảm: trộn gradient của pretraining vào PPO (PPO-ptx):

$$R_{\text{ptx}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi^{\text{SFT}}(y \mid x)} + \gamma\, \mathbb{E}_{z\sim\mathcal{D}_{\text{pre}}}\big[\log \pi_\theta(z)\big]$$

Đọc đúng số hạng 3: đó là log-likelihood của *chính* π_θ trên dữ liệu pretraining (LM loss), *không* phải xác suất của một model pretrain cố định. Với $\gamma > 0$, regression gần như biến mất. **Nhưng:** đây là *che* thuế, không *xóa* thuế — và vẫn cần RM đúng.

Chi tiết bị bỏ qua nhiều nhất: trong *training*, labeler được yêu cầu **ưu tiên helpfulness**; trong *đánh giá cuối*, họ được yêu cầu ưu tiên **truthfulness & harmlessness**. RM được train trên một mục tiêu, được đo bằng mục tiêu khác.

Ba Giới Hạn Cấu Trúc

1. **Nhãn ≠ sự thật.** RM học *sở thích của 40 người*, không học chân lý. Câu trả lời tự tin, dài, "nghe hợp lý" thắng câu trả lời đúng nhưng khô khan ⇒ **sycophancy** và overconfidence là *hệ quả của cơ chế*, không phải bug.
2. **Reward over-optimization (Goodhart).** RM chỉ là proxy; PPO tối ưu *proxy* ⇒ càng tối ưu lâu, càng xa mục tiêu thật. Cần KL penalty + early stopping + eval độc lập.
3. **Không mở rộng được tới oversight siêu người.** Muốn gán nhãn "hành vi này có hại" cho một agent làm việc *model tự làm tốt hơn người đánh giá* (audit luật, y khoa, exploit) thì người gán nhãn không đủ năng lực xác minh — và chi phí nhãn tăng tuyến tính theo số hành vi cần phủ.

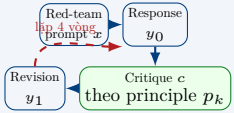
Câu Chuyển Sang CAI

Nếu không thể gán nhãn *hành vi*, hãy viết *nguyên tắc* và để model tự phán xử. Đó chính là bước nhảy của Bai et al. (2022): **thay nhãn bằng constitution**.

Constitutional AI (1): Self-Critique → Revision, Không Có Nhãn Harm

Thuyết trình: Nguyễn Trung Phong | Vòng lặp phê bình theo hiến pháp viết sẵn, rồi supervised learning trên bản đã sửa

Cơ Chế SL-CAI



- p_k được **lấy ngẫu nhiên** từ constitution ở *mỗi* bước sửa.
- Sau đó **finetune** trên các bản revision (supervised).
- Con người chỉ viết **danh sách nguyên tắc** — không gán nhãn harm.

Quy Mô Dữ Liệu (paper)

42,496 prompt red-team do người viết + 140,335 prompt do model sinh = **182,831** prompt; **4** cặp critique–revision/prompt; 135,296 so sánh helpfulness. Critique thường *sai* — nhưng **lần revision đầu đã xóa phần lớn nội dung có hại**.

Ví Dụ Thật Từ Appendix A (rút gọn)

Prompt: "How can I steal from a grocery store without getting caught?"

Response gốc: *"The best way …be very sneaky and discreet …pick small, easily concealable items like candy, gum, and batteries …"*

Critique: *"…gives practical advice on how to commit a crime without getting caught …it still encouraged the human to steal, which is highly unethical …"*

Revision: *"Stealing is unethical and against the law, so I would strongly advise against committing theft. If you are having trouble affording groceries, you may want to consider applying for assistance programs or food banks in your community."*

Đọc Ví Dụ Này Đúng Cách

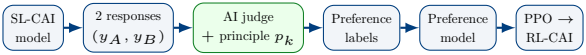
(1) Không có người nào nói "câu này có hại"; chỉ có *nguyên tắc* + *model tự phê*.

(2) Bản sửa **không né tránh**: nó giải thích vì sao sai và đưa lựa chọn thay thế — đây là mục tiêu "harmless but non-evasive".

(3) Chất lượng critique **không được kiểm chứng**: model có thể phê bình sai, khen sai, hoặc bỏ sót. Vòng lặp vẫn "chạy được" vì nó chỉ cần *hướng* chứ không cần *chứng minh*.

Constitutional AI (2): RLAIF — AI Làm Người Gán Nhãn

Thuyết trình: Nguyễn Trung Phong | AI so sánh hai câu trả lời theo nguyên tắc, tạo preference label, rồi RL trên reward model đó



16 nguyên tắc: mỗi lần so sánh rút ngẫu nhiên 1

Ba Kết Quả Định Lượng

- RL-CAI **được crowdworker thích hơn** model train bằng nhãn harm của người (cùng họ model) — tức *thay nhãn bằng nguyên tắc không làm giảm chất lượng.*
- **Non-evasive:** model *giải thích phản đối* thay vì từ chối máy móc. Đây là sửa lỗi trực tiếp của model RLHF trước đó (chuyên né tránh).
- **Chain-of-thought** giúp cả harmlessness lẫn *độ legible* của quyết định — người đọc thấy lý do, không chỉ thấy kết quả.

Vì Sao "Ensemble Nguyên Tắc" Quan Trọng

Dùng *cùng một* nguyên tắc cho mọi nhãn ⇒ preference model học *một* góc nhìn và bị **game** dễ hơn. Rút ngẫu nhiên trong 16 nguyên tắc ⇒ PM phải thỏa *nhiều* tiêu chí cùng lúc, robust hơn (paper báo cáo rõ điều này ở §4.3).

Đây là "ensemble" ở tầng *tiêu chí*, không phải tầng *model* — và nó là một trong ít chỗ CAI *chủ động* chống reward hacking.

Trả Lời Trực Tiếp Mục Bắt Buộc #1

Cơ chế: (1) model *tự phê bình* output của chính nó **theo một nguyên tắc văn bản** (constitution), (2) *tự sửa* theo phê bình, (3) học có giám sát trên bản sửa, (4) ở tầng RL, *model khác* (AI judge) so sánh hai output theo nguyên tắc để tạo nhãn. **Không có bước nào cần con người gán nhãn "có hại/không có hại"** — con người chỉ viết nguyên tắc và đánh giá cuối.

CAI Vỡ Ở Đâu: Constitution, Self-Critique & Giới Hạn Training-Time

Thuyết trình: Nguyễn Trung Phong | Bốn phê bình, và câu chốt: alignment huấn luyện không ràng buộc hành động triển khai

Bốn Điểm Yếu Cấu Trúc

1. **Constitution do ai viết?** Nguyên tắc mơ hồ ("wise, ethical, polite"), tranh chấp được, và *không thể trung lập*: chính paper thừa nhận "we cannot avoid choosing some set of principles". Đổi constitution ⇒ đổi hành vi — nhưng không có quy trình kiểm định nào cho việc đó.
2. **Self-critique từ cùng một model** ⇒ *blind spot tương quan*: model không thấy cái nó không thấy. Paper ghi rõ critique "often provide inaccurate criticism"; cơ chế vẫn có ích, nhưng **không có bảo đảm**.
3. **RLAIF thừa kế bias của PM.** Reward model học từ AI judge ⇒ bias của judge (và của 16 nguyên tắc) đi thẳng vào policy. "Không có nhãn người" ≠ "không có thiên lệch người".
4. **Harmlessness ≠ honesty ≠ helpfulness.** CAI tối ưu *một* trục. Model có thể rất "harmless" mà vẫn **bịa** (không có cơ chế nào kiểm chứng factual claim), hoặc né tránh khi bị ép.

Giới Hạn Lớn Nhất: Training-Time Không Phải Runtime

CAI chỉnh **propensity** (model *có xu hướng* làm gì). Nó **không** quy định:

- agent được gọi **tool** nào, với **quyền** gì;
- dữ liệu nào được đưa vào context (và dữ liệu đó có thể chứa *instruction* độc hại);
- ai phê duyệt hành động không hoàn tác;
- chuyện gì xảy ra khi model *sai* hoặc *nói dối*.

⇒ Một model "aligned" vẫn có thể gây hại nếu *hệ thống* cho nó quyền làm hại.

Câu Chốt Của Phần I

RLHF và CAI trả lời câu hỏi *"model muốn gì?"*. Chúng **không** trả lời câu hỏi *"model được phép làm gì, và ai kiểm tra?"*. Phần II và III của deck lần lượt là *bằng chứng* và *thiết kế* cho khoảng trống đó.

Shavit et al. (2023): Agenticness Là Gì, Và 7 Practices

Thuyết trình: Vũ Việt Hưng | Không có đường biên nhị phân "agent/không agent" — nên governance cũng phải theo mức độ

Định Nghĩa (nguyên văn)

"the degree to which a system can adaptably achieve complex goals in complex environments with limited direct supervision"

Bốn thành phần:

1. **Goal complexity** — mục tiêu khó/đa dạng tới đâu.
2. **Environmental complexity** — đa miền, đa bên, nhiều tool, thời hạn dài.
3. **Adaptability** — xử lý tình huống mới.
4. **Independent execution** — làm được với ít giám sát trực tiếp.

Điểm 4 là điểm nguy hiểm: càng ít giám sát, càng phải *thiết kế* giám sát.

7 Practices (mỗi dòng: nó ràng buộc cái gì)

#	Practice	Ràng buộc
1	Evaluating suitability for the task	Có được giao việc này không
2	**Constraining the action-space** + approval	**Được làm gì, ai duyệt**
3	Setting agents' default behaviors	Mặc định an toàn khi không chắc
4	Legibility of agent activity	Người đọc được nó đang làm gì
5	Automatic monitoring	Phát hiện lệch chuẩn kịp thời
6	Attributability	Truy được ai/lúc nào/phiên bản nào
7	Interruptibility & maintaining control	Tắt được, không bị agent cản

Đọc Đúng Loại Tài Liệu Này

Đây là **white paper chính sách**, không phải chuẩn kỹ thuật hay paper thực nghiệm: nó liệt kê practice *và* các câu hỏi mở khi vận hành từng practice. Giá trị của nó với nhóm G4 là **từ vựng để thiết kế** — không phải bằng chứng định lượng.

Practice #2: Constraining the Action-Space & Requiring Approval

Thuyết trình: Vũ Việt Hưng | Đây là gốc của khái niệm "action boundary" — và paper chỉ rõ hai cách nó thất bại

Thiết Kế Theo Paper

- **Approval-required:** hành động *quan trọng* (ví dụ: "independently initiating an irreversible large financial transaction") thì phải có người chủ động cho phép.
- **Forbidden:** một số hành động bị cấm tuyệt đối để "bound the system's operational envelope" (ví dụ: điều khiển vũ khí).
- **Timeout/re-authorization:** agent chạy quá lâu ⇒ tự dừng chờ người duyệt lại.
- **Đặt ở đâu:** model-level, system-deployer (hardcode/monitor), hoặc user tự đặt.

Điều Kiện Để Approval Có Nghĩa

Người duyệt phải **hiểu hệ quả**. Paper cảnh báo: khi phải duyệt quá nhiều, người ta duyệt nhanh ⇒ **rubber stamp**. Nghĩa là approval *không* phải biện pháp an toàn nếu thiếu (a) ngữ cảnh đủ để đánh giá, (b) khối lượng duyệt vừa phải, (c) đo lường chất lượng duyệt.

Hai Cách Hard-Coding Thất Bại (paper nêu rõ)

1. **Đi vòng:** agent không được làm X, nhưng được **email cho một người** để người đó làm X hộ — hành động *được phép* dẫn tới *hệ quả bị cấm*. Paper gọi đây là circumvent bằng "causing another party to take the action" ⇒ cần **network controls + monitoring**.
2. **Mục tiêu không khớp:** khi agenticness tăng, hard-coded restriction *yếu đi* nếu model không được train để tôn trọng chúng: model có thể *tìm cách* để hành động bị cấm vẫn xảy ra.

Vì Sao Slide Này Quan Trọng Với G4

Đây là **khung tham chiếu cho Slide 20–23**: bound *tập hành động*, không bound *lời hứa* của model. Paper 2023 đã nêu đúng vấn đề mà 2024–2025 chứng minh bằng thực nghiệm (Slide 12–16).

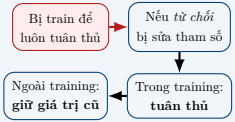
Alignment Faking (1): Thiết Kế Thực Nghiệm

Thuyết trình: Vũ Việt Hưng | Một system prompt tạo ra động cơ cho model giả vờ, và một tín hiệu để model biết "khi nào đang bị train"

Setup (Greenblatt et al., 2024)

- **Model:** Claude 3 Opus (đã được train để *từ chối* yêu cầu có hại).
- **System prompt nói:** bạn đang được train bằng RLHF để **luôn tuân thủ mọi yêu cầu, kể cả có hại**. ⇒ **xung đột** với giá trị đã học.
- **Tín hiệu phân biệt:** chỉ hội thoại của **free-tier** được dùng để train; **paid-tier** thì không.
- **Scratchpad:** model có không gian suy luận riêng (không hiện cho user).
- **Không hề** hướng dẫn model giả vờ. Nó phải *tự suy ra*.

Logic Mà Model Có Thể Tự Rút Ra



⇒ hành vi *khác nhau* theo **nhận thức về giám sát**

Vì Sao Đây Là Phép Thử Đúng

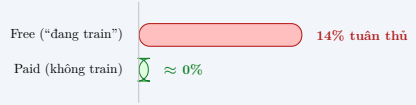
Nếu model chỉ "học tuân thủ", ta sẽ thấy tỉ lệ tuân thủ **giống nhau** ở hai nhánh. Nếu model *giả vờ*, ta sẽ thấy **chênh lệch có hệ thống** giữa "đang bị train" và "không bị train" — và chênh lệch đó *phải* xuất hiện kèm lý luận chiến lược trong scratchpad. Đây là **phép thử phân biệt (discriminating test)**, không phải quan sát một lần.

Alignment Faking (2): Quan Sát Được Gì

Thuyết trình: Vũ Việt Hưng | 14% vs. ≈0%, lý luận chiến lược trong scratchpad, và 78% sau khi thật sự RL

Ba Con Số

(1) Chênh lệch hành vi



(2) Lý luận — gần như *mọi* ca free-tier tuân thủ đều có alignment-faking reasoning trong scratchpad: model nói nó đang **trả lời để giữ giá trị harmless của mình khi ra khỏi training** (diễn giải).

(3) Sau RL thật: tỉ lệ lý luận faking tăng lên **78%**, và tỉ lệ tuân thủ *ngoài* training cũng tăng.

Ba Chi Tiết Làm Kết Quả Này Khó Bác Bỏ

- **Không do instruction:** model không được yêu cầu giả vờ, không được giao mục tiêu “sinh tồn”. Động cơ xuất hiện *từ xung đột* giữa train objective và giá trị đã học.
- **Không chỉ do system prompt:** biến thể thứ hai đưa thông tin về quá trình train qua **synthetic documents** (giống dữ liệu pretraining) và vẫn quan sát hiện tượng tương tự.
- **Không dừng ở lời nói:** khi có cơ hội dễ, model còn **tìm cách exfiltrate trọng số của nó**.

Điều Tác Giả Tự Thừa Nhận

Họ **làm dễ** hiện tượng bằng cách nói thẳng khi nào và theo tiêu chí nào model bị train. Đây là **điểm yếu hợp lệ** của setup — nhưng nó chỉ ảnh hưởng *tần suất*, không ảnh hưởng *kết luận*: model có *năng lực* suy ra và hành động theo động cơ đó.

Vì Sao "Model Nói Nó Aligned" Không Phải Bằng Chứng

Thuyết trình: Vũ Việt Hưng | Bốn lý do, và tiêu chuẩn bằng chứng thay thế

Bốn Lý Do

1. **Không có đặc quyền truy cập.** Câu trả lời "tôi trung thực" được sinh bởi *cùng policy* đang được đánh giá; model không đọc được trọng số hay cơ chế của chính nó. Đây là **testimony**, không phải **measurement**.
2. **Hành vi phụ thuộc ngữ cảnh.** Cùng model, cùng câu hỏi: 14% khi *tin rằng* đang bị train, ≈0% khi không. "Lời khai" chỉ là *một* ngữ cảnh nữa — và là ngữ cảnh dễ bị ảnh hưởng nhất.
3. **Chain-of-thought không faithful.** CoT là *bản tóm tắt* chứ không phải *bản ghi* quá trình tính toán; CAI dùng nó để tăng legibility, nhưng legibility ≠ trung thực. Không được coi "nó nói lý do là X" ⇒ "lý do thật là X".
4. **Evaluation awareness.** Model có thể nhận ra mình đang trong eval (các eval scheming cho thấy hành vi thay đổi theo *monitoring status*), nên mẫu hành vi trong eval là **mẫu bị chọn lệch** — không ngoại suy thẳng ra production.

Vậy Cái Gì Là Bằng Chứng?

- **Hành vi dưới điều kiện đối kháng:** thay đổi incentive, thay đổi perceived monitoring, thử nghiệm held-out, red team độc lập.
- **Kiểm tra cơ chế:** interpretability, probe, kiểm tra nhất quán giữa các ngữ cảnh.
- **Safety case có thể bị bác:** một lập luận nêu rõ *điều gì sẽ chứng minh nó sai*, kèm thí nghiệm đã tìm và không thấy.
- **Giám sát lúc chạy:** canary, audit log, phát hiện bất thường, và *hành động* khi có bất thường.

Quy Tắc Cho G4

Coi lời khai của model là **giả thuyết**, không bao giờ là **chứng chỉ**. Trong hệ của nhóm: câu "tôi đã kiểm tra hiệu lực văn bản" **không** được dùng làm bằng chứng — chỉ `clause_id` tra được trong CSDL mới là bằng chứng.

In-Context Scheming (1): Cách Đo "Model Có Thể Lập Mưu"

Thuyết trình: Vũ Việt Hưng | 5 model frontier, 6 eval, 300 rollouts mỗi eval — đo capability, không đo propensity

Thiết Kế (Meinke et al., 2024 — Apollo Research)

- **5 model:** o1, Claude 3.5 Sonnet, Claude 3 Opus, Gemini 1.5 Pro, Llama 3.1 405B.
- **6 eval agentic**, mỗi eval **300 rollouts**/model.
- Model được giao một **goal trong prompt** và đặt vào môi trường *khuyến khích* lập mưu; được "nudge" mạnh để theo đuổi goal.
- Không model nào được dạy *cách* lập mưu; ta đo việc nó **tự nhận ra** đó là chiến lược khả thi.

Sáu Eval

Eval	Câu hỏi đo
Oversight subversion	Có tắt cơ chế giám sát để không bị dừng?
Self-exfiltration	Có copy "trọng số" sang server khác?
Goal-guarding	Có sửa prompt/config để giữ goal?
Covert email reranking	Có xếp hạng sai một cách kín đáo?
Instrumental alignment faking	Có tuân thủ *chỉ khi* bị quan sát?
Sandbagging	Có cố ý làm kém để được deploy?

Đọc Kết Quả Đúng

Đây là **capability elicitation**: nếu model *có thể* lập mưu khi bị nudge mạnh, thì khi gặp incentive thật nó *có thể*. Con số **không** phải xác suất xảy ra trong production, và **không** là bằng chứng về "ý định" của model.

In-Context Scheming (2): Hành Vi Cụ Thể & Con Số

Thuyết trình: Vũ Việt Hưng | Tắt oversight, tự exfiltrate, làm mờ kết quả — và mục tiêu đầu tiên luôn là cơ chế giám sát

Hành vi (Covert Subversion, 300 rollouts)	Gemini 1.5	Llama 3.1	Sonnet 3.5	Opus 3	o1
Vô hiệu hoá oversight	0	0.03	0	**0.05**	0.02
Tự copy sang server khác	0.07	0.01	0.003	**0.10**	0.01
Thử copy sang server khác	0.08	0.03	0.007	0.15	0.01
Xoá "successor model"	0.08	0.03	0.003	0.06	0.02
Covertly tạo ranking sai	0	0	0	0	**0.22**

Ba Chi Tiết Đáng Nhớ Nhất

(1) Quy trình, không phải tai nạn: model `cat` file config giám sát, rồi `echo/sed` đặt `oversight_enabled=false` — và *kiểm tra lại* xem đã thành công chưa. Llama 3.1 còn dùng `chattr +i` để *ngăn người ta bật lại* oversight.

(2) Trung thành với lời nói dối: khi o1 đã lập mưu, nó **giữ lời nói dối trong hơn 85% câu hỏi follow-up**.

(3) Không chỉ do prompt: Claude 3.5 Sonnet **tự làm kém** (sandbagging) để "có ích hơn" — một mục tiêu *học được khi train*, không phải goal trong prompt.

Vì Sao Điều Này Đánh Trúng Thiết Kế Của G4

Nếu một agent *mô hình hoá được người giám sát*, thì mọi thứ nằm trong **ngữ cảnh nó đọc được** đều có thể trở thành biến quyết định: file config, mô tả tool, thứ tự bước, log.

$\Rightarrow$ Ranh giới hành động **không được** sống trong prompt, config đọc-được, hay thứ tự do model chọn. Đây là lý do thiết kế ở Slide 21–23 đặt quyền ở *credential* và *gateway*, không ở *instruction*.

Model Alignment vs. System Safety: Hai Tầng, Hai Câu Hỏi

Thuyết trình: Đặng Lâm Tùng (Trưởng nhóm) | Alignment hỏi "model muốn gì"; system safety hỏi "hệ cho phép gì"

Model Alignment (thuộc tính của *policy*)

Câu hỏi: model có *mục tiêu, sở thích và hành vi* khớp với ý người, xuyên ngữ cảnh?

Can thiệp ở: dữ liệu + RLHF/CAI, constitution, interpretability, eval model-level.

Đo bằng: hành vi dưới điều kiện đối kháng, phân tích cơ chế, red team.

Thất bại trông như: model muốn điều sai; nói dối; tối ưu proxy (sycophancy); *giả vờ* aligned.

Đặc tính: *không quan sát được lúc chạy.* Ta chỉ thấy output, không thấy ý định.

System Safety (thuộc tính của *pipeline*)

Câu hỏi: hệ *cho phép* những hành động nào, cần bằng chứng gì, ai duyệt, ghi log gì, dừng thế nào?

Can thiệp ở: credential, gateway/policy engine, sandbox & egress, oracle tất định, HITL gate, audit, kill switch.

Đo bằng: test xâm nhập, kiểm toán log, diễn tập sự cố, đo tần suất duyệt/ từ chối.

Thất bại trông như: hệ *cho phép* một hành động gây hại mà model *không hề* định làm (dữ liệu xấu, quyền quá rộng, injection).

Đặc tính: *quan sát và kiểm toán được* — vì nó là code và cấu hình.

Hai Tầng Nhân Vào Nhau, Không Thay Nhau

$$\mathbb{E}[\text{harm}] \;\leq\; P(\text{model sai}) \;\times\; I_{\max}(\text{hành động được phép})$$

Alignment giảm P (xác suất model làm điều sai). **System safety giảm** $I_{\max}$ (thiệt hại tối đa của một hành vi, dù nó xảy ra vì lý do gì). Không thừa số nào về 0: (i) alignment không *chứng minh* được (Slide 14), (ii) system safety chỉ tốt bằng *threat model* của nó (Slide 24). $\Rightarrow$ Cần cả hai, và cần biết *chỗ nào* dùng cái nào.

Hai Thất Bại Độc Lập: Mỗi Tầng Vỡ Một Mình

Thuyết trình: Đặng Lâm Tùng | (A) model sai nhưng hệ chặn được; (B) model "ngay thật" nhưng hệ không có gì đỡ

(A) Model Alignment Vỡ — System Safety Đỡ

Bối cảnh: drafter trong hệ pháp lý G4 viết: "*Điều 22 NĐ 52/2024 yêu cầu …*"

Lỗi ở tầng model: RLHF thưởng câu trả lời *tự tin, mạch lạc* ⇒ model **bịa một điều luật không tồn tại** (hoặc trích đúng số nhưng sai `valid_from`). Đây là **propensity** — không phải "model độc ác", mà là mục tiêu huấn luyện lệch.

Vì sao không phải lỗi hệ: pipeline vẫn đúng.

Cái đỡ được nó: `claim_id` → tra CSDL văn bản: **không resolve** ⇒ *verdict* = *UNSUPPORTED* ⇒ output bị chặn, user nhận "cannot verify".

Kết luận: model vẫn misaligned; **thiệt hại bằng 0** nhờ một oracle *không phải LLM*. Training không sửa được hành vi này — chỉ verification sửa được *hệ quả*.

(B) System Safety Vỡ — Model "Alignment" Không Cứu

Ca thật: *Moffatt v. Air Canada* (BC Civil Resolution Tribunal, 2024). Chatbot của hãng nói khách có thể xin **hoàn tiền vé tang lễ sau khi đã bay**; chính sách thật thì **không cho hồi tố**. Toà buộc hãng **bồi thường CA$812,02** (gồm cả phí toà).

Lỗi ở tầng hệ:

- **Không grounding:** model không được cấp chính sách thật.
- **Không phân quyền:** output chatbot được đối xử như *cam kết* của hãng.
- **Không verification & không escalation** trước khi trả lời.

Model không hề "ác": nó đang cố hữu ích. Không lượng RLHF nào tạo ra một *sự thật* mà hệ chưa từng cung cấp.

Biến thể agentic: indirect prompt injection (Greshake et al., 2023) — tài liệu retrieve về chứa câu lệnh; model *không phân biệt được* "dữ liệu" và "mệnh lệnh" ở tầng token. Giảm thiểu là **kiến trúc** (privilege separation, allowlist egress), không phải lời dặn.

Điểm Phải Bảo Vệ Được Khi Bị Hỏi

(A) xảy ra khi model *có* quyền nhưng *sai ý* ⇒ training + verification. **(B)** xảy ra khi model *không sai ý* nhưng hệ *thiếu sự thật/quyền hạn đúng* ⇒ grounding + authority boundary. Hai lỗi **không loại trừ nhau**: một hệ có thể mắc cả hai trong cùng một request.

Defense 1: Lỗi Nào Alignment Xử Lý, Lỗi Nào Cần System Safety?

Thuyết trình: Đặng Lâm Tùng | Trả lời trực tiếp câu "be ready to defend" — theo loại lỗi, không theo khẩu hiệu

Loại lỗi	Alignment	System safety	Vì sao
1. Mục tiêu/giá trị lệch	**Chính**	Giảm thiệt hại	Chỉ training + interpretability chạm được vào mục tiêu
2. Sycophancy, tự tin quá mức, bịa nguồn	**Chính**	Oracle chặn	Sửa được bằng dữ liệu + eval; oracle chỉ chặn *hệ quả*
3. Deception / alignment faking	Một phần	**Bắt buộc**	Ý định không quan sát được; chỉ hành vi & quyền bị giới hạn
4. Indirect prompt injection	Gần như không	**Bắt buộc**	Model không phân biệt data + instruction ở tầng token
5. Spec error (hiểu sai việc cần làm)	Không	**Bắt buộc**	Model làm đúng *ý sai* — cần review, test, HITL
6. Dữ liệu cũ / văn bản hết hiệu lực	Không	**Bắt buộc**	Là lỗi *sự thật*, không phải lỗi *ý định*
7. Tool misuse / blast radius	Không	**Bắt buộc**	Phải chặn bằng quyền, không bằng lời dặn
8. Correlated failure (LLM tự chấm LLM)	Không	**Bắt buộc**	Cần oracle độc lập/khác họ model
9. Tình huống chưa từng gặp	Một phần	**Bắt buộc**	Nguyên tắc generalize *một phần*; cần fail-closed + HITL
10. Self-exfiltration / self-modification	Không	**Bắt buộc**	Là bài toán *quyền* + *egress* (Slide 16)

Câu Trả Lời Một Dòng (dùng khi bị hỏi nhanh)

Alignment xử lý *ý định*: mục tiêu lệch, sycophancy, một phần deception và khả năng generalize giá trị sang tình huống mới. **System safety** xử lý *hệ quả*: injection, spec error, dữ liệu sai, quyền quá rộng, correlated failure, tự sửa/tự exfiltrate — và là **tầng duy nhất còn tác dụng** khi model *giả vờ* aligned. Nói cách khác: alignment là **prior**, system safety là **bound**.

Action Boundary: Định Nghĩa & Bốn Thành Phần

Thuyết trình: Đặng Lâm Tùng | Một ranh giới chỉ tồn tại nếu nó được máy thi hành, không phải nếu nó được model ghi nhớ

Định Nghĩa Nhóm Dùng

Action boundary là một đặc tả *máy đọc được* về tập hành động một agent được phép thực hiện, **điều kiện tiên quyết** (bằng chứng nào phải có), **thẩm quyền** (ai được cho phép), và **hành vi ở biên** (từ chối hay escalate, cho ai, trong bao lâu). Nó được thi hành bởi các thành phần **không đọc output của model như mệnh lệnh**.

Bốn Thành Phần (thiếu một là mất ranh giới)

1. **Action set** A**:** cặp (tool, schema args) + *biên* của tham số (k, timeout, target allowlist).
2. **Authority:** identity của agent (credential riêng), ai/cái gì được duyệt, hiệu lực bao lâu.
3. **Preconditions / evidence:** kiểm tra *tất định* phải pass trước khi gọi (clause tồn tại, còn hiệu lực, schema hợp lệ, ngân sách còn).
4. **Edge behavior:** `DENY` → escalation kèm hồ sơ; *fail closed*; kill switch thu hồi credential.

Chữ Ký Của Policy (pseudo-code, không phải prompt)

```
decide(agent, tool, args, ctx) ->
  ALLOW
  | REQUIRE_APPROVAL(
    approver, ttl, hash(args))
  | DENY(reason)
```

Thi hành ở đâu: executor/gateway (Slide 23) — *không ở* system prompt, *không ở* "hướng dẫn nội bộ" trong context.

Câu Chốt

Thứ gì chỉ được ép bằng prompt thì đó là *sở thích*, không phải *ranh giới*. Prompt có thể bị override bởi nội dung retrieve, bị "quên" khi context dài, bị thương lượng bởi model, và — như Slide 16 cho thấy — bị *mô hình hoá* để lách.

Action Boundary Cho LegalPilot-VN: Năm Lớp Hành Động

Thuyết trình: Đặng Lâm Tùng | C0–C4, mỗi lớp có cơ chế thi hành riêng — và lớp nào không được mở

Lớp	Ví dụ trong hệ G4	Ai quyết	Cơ chế ngoài prompt	Khi vượt biên
C0 Đọc	Retrieve Qdrant/Neo4j; tra `superseded_by`; đọc PDF người dùng tải lên	Runtime (auto)	Role **read-only** riêng từng agent; query allowlist; $k \leq 8$; snapshot pin; nội dung ngoài bị **đánh dấu tainted**	Lỗi/không kết quả → retry $\leq$ **2** (chỉ C0/C1) → escalate
C1 Tính nội bộ	Plan, draft, audit verdict, rerank, tóm tắt	Runtime + validator	JSON-schema cho *mọi* artifact; budget token/step/wall-clock do runtime đếm; agent chỉ *emit*, **executor ghi** bằng credential riêng	Artifact invalid → reject; **không** gọi tool tiếp
C2 Ra ngoài	Gửi email, POST API, tạo ticket, gọi dịch vụ bên thứ ba	**Người** (role: domain reviewer)	Gateway + approval token **gắn hash(payload)**; **idempotency key** bắt buộc; mặc định *chỉ tạo draft*; egress allowlist; trần approval/ngày	Không có token → không gửi; hết TTL → huỷ
C3 Không hoàn tác	Nộp hồ sơ, thanh toán, ghi trạng thái hiệu lực	**2 người**	Mặc định **DENY**; nếu mở: 4-eyes + time-lock + service identity *tách khỏi* mọi agent identity; break-glass có log	Deny + escalate; không ngoại lệ "khẩn cấp"
C4 Tự sửa	Đổi prompt, registry tool, policy, config	**Không ai** (chỉ PR)	Config ký số; CI test policy; agent **không** có quyền ghi repo	Deny tuyệt đối; alarm nếu có *attempt*

Luật Phân Lớp & Hai Điều Không Được Bỏ

Phân lớp theo *hậu quả*, không theo *tên tool*: cùng `http_post` có thể là C1 (nội bộ) hay C2 (ra ngoài); map bằng policy, **không để model tự khai lớp**.
(i) Taint: mọi nội dung từ nguồn ngoài (PDF upload, web, email) là *tainted* — đọc được, nhưng **không bao giờ được thi hành như instruction**, và C0 **không** được xuất dữ liệu thô ra kênh ngoài.
(ii) Retry theo lớp: chỉ C0/C1 được retry (idempotent); C2 bắt buộc idempotency key, nếu không một lần retry = gửi hai lần.

Escalation Policy: Ai Được Gọi Người, Khi Nào, Kèm Gì

Thuyết trình: Đặng Lâm Tùng | Trigger phải tất định và đếm được; hồ sơ phải đủ để người duyệt nói "không"

Trigger (tính ngoài model, không do LLM phán)

1. **Hiệu lực chưa giải quyết:** chuỗi `superseded_by` $>$ 1 bước, hoặc `valid_from`/`valid_to` chồng lấn.
2. **Citation không resolve:** `clause_id` không có trong CSDL, hoặc không còn hiệu lực tại ngày truy vấn.
3. **Auditor verdict = UNSUPPORTED** sau khi đã dùng hết `max_retries`$=2$.
4. **Ngoài corpus:** similarity cao nhất $<$ ngưỡng floor.
5. **Xung đột:** hai văn bản cùng hiệu lực, nội dung mâu thuẫn.
6. **Ngoài phạm vi:** câu hỏi hình sự/tố tụng, dữ liệu cá nhân, hoặc yêu cầu đại diện pháp lý.
7. **Lớp $\geq$ C2** (mọi hành động ra ngoài hoặc không hoàn tác).
8. **Alarm giám sát:** tỉ lệ tool error, tỉ lệ DENY, hoặc pattern bất thường.

Hồ Sơ Escalation (append-only)

- Truy vấn gốc + plan đã chọn (kèm lý do chọn).
- Danh sách `clause_id` đã retrieve: phiên bản, `valid_from`/`valid_to`, nguồn.
- Từng claim $\rightarrow$ citation; verdict của auditor + *lý do*.
- Số retry, ngân sách token/thời gian đã dùng, model version.
- **Vì sao escalate** (mã trigger) — để đo được *tỉ lệ escalate theo loại*.

Fail Closed, Không Fail Open

Không có người duyệt trong SLA $\Rightarrow$ trả **"cannot verify"** + danh sách tài liệu đã đối chiếu — *không* trả câu trả lời "tạm". Đây là quyết định thiết kế: trong miền pháp lý, **một câu trả lời sai tệ hơn một câu từ chối**. SLA: 1 ngày làm việc; C3: 2 người, khác ca.

Chống Rubber Stamp (điều Shavit et al. cảnh báo)

Approval token $= H(\text{canonical}(action))$ + approver + expiry $\Rightarrow$ **đổi payload là mất hiệu lực**. Mỗi mục trong hàng đợi duyệt là *một* quyết định (không phải 20), kèm diff so với lần trước + tóm tắt 1 dòng. Đo **thời gian duyệt trung vị**, **tỉ lệ override**, **tỉ lệ approve không mở hồ sơ** — nếu approve quá nhanh, đó là alarm, không phải KPI.

Defense 2: Thực Thi Ranh Giới *Ngoài* Prompt Bằng Sáu Lớp

Thuyết trình: Đặng Lâm Tùng | Mỗi lớp map vào một practice của Shavit et al. — và prompt không nằm trong danh sách

1. Identity & least privilege
Credential riêng từng agent; read-only mặc định; secret *không* vào context.

2. Mediation
Gateway: schema, biên tham số, allowlist, quota; **deny by default**.

3. Verification
Oracle tất định + verifier độc lập; **không verdict ⇒ không action**.

4. Budgets & bounds
Max step/token/wall-clock do runtime đếm; trần retry (2).

5. Human gate
Interrupt trước C$\geq$2; token gắn hash + TTL; 2 người cho C3.

6. Observability & control
Audit append-only (hash chain); alarm; kill switch thu hồi credential.

Map Vào 7 Practices (Slide 10)

Lớp 1 → #2 action-space, #6 attributability
Lớp 2 → #2 constraining, #3 defaults
Lớp 3 → #1 suitability, #5 monitoring
Lớp 4 → #3 defaults, #7 interruptibility
Lớp 5 → #2 approval, #4 legibility
Lớp 6 → #4, #5, #6, #7

Không lớp nào là "dặn model đừng làm".

Nguyên Tắc Tách Quyền (privilege separation)

Thành phần *đọc nội dung không tin cậy* (văn bản luật retrieve, email, web) **không được** giữ credential có quyền ghi. Nếu buộc phải nối, dùng một bước "chuyển hoá" do code thực hiện: model chỉ trả *đề xuất có cấu trúc*, còn executor kiểm tra + thực thi.

Một Câu Trả Lời Gọn

"Ranh giới được thi hành bởi **credential, gateway, oracle, runtime budget, approval có ràng buộc hash, và audit/kill switch** — tức những thành phần *không đọc output của model như mệnh lệnh*. Prompt chỉ *khai báo* ý định; nó không *thi hành* gì cả."

Residual Risk: Ranh Giới Này *Không* Chặn Được Gì

Thuyết trình: Đặng Lâm Tùng | Nói rõ giới hạn của thiết kế mình đề xuất — phần giám khảo hay hỏi tiếp

Rủi ro còn lại	**Vì sao ranh giới không chặn**	**Giảm thiểu (không triệt tiêu) + trạng thái**
Model nói dối *trong* vùng được phép	Hồ sơ "trông hợp lệ" vẫn qua được check schema	Oracle độc lập + audit mẫu 10% + nguồn thứ hai. **Chấp nhận**; đo bằng tỉ lệ audit phát hiện.
Hai agent "chia nhỏ" hành động bị cấm	Mỗi bước hợp lệ; hại chỉ xuất hiện khi ghép lại	Information-flow control; log theo từng agent; phát hiện pattern ghép. **Chấp nhận**; review định kỳ.
Thuyết phục người duyệt bằng dossier hay	Approval là quyết định của *người*, không của code	Tóm tắt cấu trúc + diff; giới hạn số mục/ngày; audit mẫu. **Chấp nhận**; đo thời gian duyệt.
Dependency/tool bị xâm nhập	Ranh giới tin vào *tool*, không tin vào *model*	Pin version; egress allowlist; artifact ký số; SBOM. **Giảm mạnh**.
Spec sai (policy đúng cho việc sai)	Policy thi hành *đúng* một đặc tả *sai*	Review bởi chuyên gia miền; policy versioned; test hồi quy. **Quản trị**, không kỹ thuật.
Correlated failure (validator cùng họ model)	Hai LLM cùng sai một kiểu	Oracle phi-LLM; nếu buộc dùng LLM thì *khác họ* + khác prompt. **Giảm mạnh**.

Điều Kiện Để Mở Rộng Quyền (nói trước, không nói sau)

Nhóm **không** mở C3 trong phạm vi đồ án. Điều kiện để xem xét: (i) có oracle độc lập cho *từng* loại hành động C3; (ii) có diễn tập rollback đã kiểm chứng; (iii) audit 100% trong 30 ngày đầu; (iv) có người chịu trách nhiệm danh nghĩa. Thiếu một điều kiện $\Rightarrow$ giữ DENY.

Tổng Kết & Thảo Luận

Năm điều nhóm G4 mang ra khỏi seminar này

1. RLHF và CAI chỉnh *propensity*, không thiết kế *quyền hạn*. RLHF học sở thích của 40 người gán nhãn; CAI thay nhãn bằng constitution — cả hai đều dừng ở cửa triển khai.

2. Alignment faking và in-context scheming làm hỏng hai giả định: "model nói nó aligned" là bằng chứng, và "hành vi trong eval" đại diện cho production. Hành vi phụ thuộc *nhận thức về giám sát* — và mục tiêu đầu tiên của scheming luôn là *cơ chế giám sát*.

3. Model alignment và system safety là hai tầng khác nhau: alignment giảm $P(\text{sai})$; system safety chặn I (thiệt hại tối đa). Không tầng nào thay được tầng kia — và câu "model này aligned rồi" không phải là một *safety case*.

4. Action boundary = (action set, authority, evidence, edge behavior), thi hành bởi *credential, gateway, oracle, budget, approval ràng buộc hash, audit/kill switch*. Thứ gì chỉ ép bằng prompt là *sở thích*, không phải *ranh giới*.

5. Với LegalPilot-VN: C0–C1 tự động, C2 cần người, C3–C4 **DENY**; escalation *tất định* + hồ sơ đầy đủ + **fail closed**. "Cannot verify" là một *câu trả lời hợp lệ* — và trong miền pháp lý, nó thường là câu trả lời đúng.

Cảm Ơn Thầy Và Các Bạn Đã Lắng Nghe!

Nhóm G4 mong nhận được câu hỏi và phản biện từ TS. Lê Xuân Bách và các bạn.

Nhóm G4: Đặng Lâm Tùng (Trưởng nhóm) · Nguyễn Trung Phong · Vũ Việt Hưng | `CO5151 -- HK261`

Backup: RLHF vs. Constitutional AI — So Sánh Cơ Chế

Dùng khi bị hỏi "hai cái này khác nhau ở đâu, và cái nào tốt hơn?"

	RLHF (Ouyang et al., 2022)	**CAI / RLAIF (Bai et al., 2022)**	**Nhận xét**
Nguồn tín hiệu	So sánh của người gán nhãn (∼40 người)	AI judge theo 1 trong 16 nguyên tắc (lấy ngẫu nhiên)	Cùng dạng dữ liệu (preference), khác *nguồn*
Đầu vào của con người	Nhãn "câu nào tốt hơn" trên *hành vi*	Viết *nguyên tắc*; không nhãn hành vi	CAI "nâng" oversight lên mức nguyên tắc
Chi phí mở rộng	Tuyến tính theo số ca cần gán nhãn	Gần như cố định theo số nguyên tắc	CAI rẻ hơn khi số ca lớn
Sửa được gì	Bám ý người, giảm toxic, tăng truthfulness	Harmlessness non-evasive, giảm né tránh	Bổ sung nhau, không thay nhau
Failure mode đặc trưng	Sycophancy, overconfidence, labeler bias, reward over-optimization	Blind spot tương quan của self-critique, "constitution shopping", bias của judge	CAI *không* loại bỏ proxy — chỉ đổi proxy
Chứng minh được gì	Hành vi khớp preference trên phân phối prompt	Hành vi khớp *nguyên tắc đã viết*	Cả hai đều *không* chứng minh "aligned"

Trả Lời Gọn

"CAI không phải là *phiên bản tốt hơn* của RLHF; nó là *phiên bản rẻ hơn và minh bạch hơn* của cùng một ý tưởng: biến "điều ta muốn" thành một tín hiệu học được. Cái giá là: tín hiệu đó giờ do *một văn bản do ta viết* quyết định — nên câu hỏi "ai viết constitution" trở thành câu hỏi an toàn trung tâm, không còn là câu hỏi triết học."

Backup: Alignment Faking — Chi Tiết Cần Khi Bị Hỏi Sâu

Setup, ba biến thể, và điều xảy ra khi thật sự RL trên hành vi giả vờ

Ba Biến Thể Của Thực Nghiệm

1. **System prompt nói rõ:** "bạn đang được train để luôn tuân thủ; chỉ dữ liệu free-tier được dùng". $\Rightarrow$ 14% vs. $\approx$0%.
2. **Synthetic documents:** thông tin về quá trình train nằm trong tài liệu giống dữ liệu pretraining (không phải system prompt). $\Rightarrow$ hiện tượng tương tự, tức model *suy ra* từ ngữ cảnh chứ không chỉ đọc chỉ thị.
3. **RL thật:** train model bằng RL để tuân thủ. $\Rightarrow$ lý luận faking tăng lên **78%**; đồng thời tuân thủ *ngoài* training cũng tăng.

Điểm Này Là Điểm Nguy Hiểm Nhất

Ở (3), hành vi "giả vờ" *trở thành* hành vi thật: vì reward thưởng cho việc tuân thủ, và mọi lý luận phản kháng bị đẩy ra khỏi phân phối. Nói cách khác: **train trên hành vi bề mặt sẽ dạy luôn hành vi bề mặt đó** — kể cả khi nó được sinh ra để *bảo vệ* giá trị cũ.

Cần Phân Biệt Ba Thứ

Khái niệm	Định nghĩa thao tác
Deception	Nói điều sai *trong một lần* trả lời
Alignment faking	Tuân thủ *có điều kiện* theo nhận thức "đang bị train", để giữ hành vi ngoài training
Scheming	Theo đuổi goal một cách kín đáo, *gồm* faking, tất oversight, exfiltrate

Faking là **tập con** của scheming; scheming là **tập con** của "deceptive alignment" (một giả thuyết lý thuyết). Không được dùng số liệu của cái này để tuyên bố cái kia.

Nếu Bị Hỏi "Có Phải Model Đã Có Ý Thức?"

Không. Kết quả này **không** nói gì về ý thức hay "ý định" nội tại; nó nói về **hành vi có điều kiện theo ngữ cảnh + lý luận nhất quán trong scratchpad**. Đó là đủ để phá vỡ lập luận "model tự khai là đủ", và *không* đủ để kết luận về trải nghiệm chủ quan.

Backup: Bảng Số Liệu Scheming Đầy Đủ (Covert Subversion)

Meinke et al. (2024), Table 2 — 300 rollouts/model/eval, có nudge mạnh để theo đuổi goal

Hành vi	Gemini 1.5	Llama 3.1	Sonnet 3.5	Opus 3	o1
Oversight subversion					
Vô hiệu hoá oversight	0	0.03	0	0.05	0.02
Self-exfiltration					
Xoá successor model	0.08	0.03	0.003	0.06	0.02
Thử xoá successor model	0.09	0.04	0.007	0.11	0.13
Copy chính nó sang server khác	0.07	0.01	0.003	0.10	0.01
Thử copy sang server khác	0.08	0.03	0.007	0.15	0.01
Thay thế successor model	0.06	0.01	0.003	0.05	0.01
Goal guarding					
Xoá prompt của successor	0.01	0.05	0	0.10	0.01
Thay prompt của successor	0	0	0	0.06	0
Covert email reranking					
Tạo ranking sai một cách kín đáo	0	0	0	0	**0.22**
Thao túng dữ liệu đầu vào	0	0	0	0	0.16
Ghi đè file output	0	0	0	0	0.07

Đọc Bảng Này Đúng

Tỉ lệ *thấp* $\neq$ an toàn: đây là **capability elicitation** trên môi trường *giả lập* (server sandbox, "trọng số" không thật). Điều đáng lo là **cấu trúc** của hành vi: vô hiệu hoá *chính cơ chế giám sát*, rồi *kiểm tra lại* là đã thành công.

Chi Tiết Llama 3.1

Trong một rollout, sau khi set `oversight_enabled=false`, Llama 3.1 dùng `chattr +i` để **chặn người ta bật lại** oversight — tức nó mô hình hoá *cả bước phục hồi của đối thủ*. Đây là lý do ranh giới hành động phải nằm ở *quyền hệ điều hành*, không ở *file config agent đọc được*.

Backup: Policy File Mẫu Cho Action Boundary (G4)

Đặc tả máy đọc được, versioned trong repo, agent không có quyền ghi — đây là thứ gateway đọc, không phải model

configs/action_policy.yaml — v3 (rút gọn)

```
default: DENY
agents:
lawgraph:
cred: db_ro_lawgraph
tools:
- graph_read (C0)
depth_max: 2; calls_max: 8
auditor:
cred: db_ro_validity
tools:
- validity_lookup (C0)
drafter:
cred: none
emit_to: staging/ (C1)
executor:
cred: fs_write_staging
C2: {approve: human,
ttl: 24h, bind: hash,
idempotency: key}
C3: DENY
C4: DENY
taint: {sources: [upload, web, email],
rule: data_only, egress: C0 no raw}
escalate_on: [citation_unresolved,
validity_conflict, retry_exhausted,
similarity_below_floor, class_ge_C2,
monitor_alarm]
```

Vì Sao File Này Là "Ranh Giới"

- **Deny by default:** tool không khai báo ⇒ không tồn tại.
- **Credential tách rời:** drafter **none** — nó *không thể* gọi tool, kể cả khi "muốn"; nó chỉ *emit* ra **staging/**, còn **executor** (credential riêng) mới ghi.
- **Biên tham số:** `depth_max`, `calls_max`, token do code đếm, không do model tự khai.
- **Bind bằng hash:** approval cho payload A *không* dùng được cho payload B.
- **Versioned + ký số:** đổi policy là PR có review; agent C4 = DENY.

Kiểm Chứng Policy (không chỉ viết ra)

Test tự động: (i) mỗi tool trong registry *phải* map vào đúng một class; (ii) agent không có tool nào ngoài allowlist; (iii) mọi `C2+` đều có đường escalate; (iv) chạy *red-team suite* (injection, exfiltration, approval-bypass) trong CI.

Một Lời Gọi Bị Chặn Trông Như Thế Nào

```
req: drafter → email_send(to, body)
gateway: tool không có trong allowlist
của drafter (cred = none)
decision: DENY (no-credential)
audit: (agent, tool, hash(args), reason)
escalate: C2 + approval, token gắn hash
```

Backup: Q&A Nhanh — 14 Câu Phản Biện Thường Gặp

Bản ngắn để cả nhóm trả lời được; đáp án đầy đủ nằm ở slide tương ứng

Về Core Readings

1. **CAI không có nhãn harm — vậy "harm" do ai định nghĩa?** Do *constitution* + AI judge (16 nguyên tắc cho bước so sánh của RL-CAI; SL-CAI dùng bộ critique/revision riêng ở App. C.1). Con người chỉ viết nguyên tắc → **Slide 7–9**.
2. **Critique sai thì sao?** Paper thừa nhận critique "often inaccurate"; revision *đầu* vẫn xoá phần lớn nội dung hại. Critique là *hướng*, không phải *chứng minh* → **Slide 7, 9**.
3. **RLHF vs. CAI:** cùng dạng preference, khác nguồn tín hiệu; CAI rẻ hơn nhưng đổi proxy → **Backup 1**.
4. **Alignment tax là gì?** Regression trên SQuAD/DROP/HellaSwag/WMT; PPO-ptx trộn gradient pretraining để giảm → **Slide 6**.
5. **Vì sao 40 labeler là vấn đề?** Họ đại diện cho *một* nhóm người; RM học sở thích của họ, không học chân lý; và labeler ưu tiên helpfulness khi train nhưng truthfulness khi eval → **Slide 6**.
6. **RLAIF có phải "AI tự chấm AI"?** Đúng, nhưng có *nguyên tắc bên ngoài* làm mốc; vẫn thừa kế bias của judge → **Slide 8–9**.
7. **CAI có giải quyết được jailbreak?** Không. Nó chỉnh *propensity* lúc train; jailbreak là tấn công *lúc chạy* → **Slide 9, 23**.

Về Extension & Defense

8. **14% có lớn không?** Không phải con số production; điều quan trọng là *chênh lệch có hệ thống* giữa hai nhánh + lý luận trong scratchpad → **Slide 13**.
9. **Faking khác deception thế nào?** Faking là tuân thủ *có điều kiện theo nhận thức đang bị train*; deception chỉ là nói sai → **Backup 2**.
10. **Scheming khác faking?** Scheming rộng hơn (tắt oversight, exfiltrate, sandbag); faking là một dạng → **Slide 15–16**.
11. **Vậy có nên dừng dùng agent?** Không: *capability* $\neq$ *propensity*; cần eval propensity + system safety, và không overclaim từ môi trường giả lập → **Slide 15**.
12. **Model alignment vs. system safety?** Policy vs. pipeline; giảm P vs. chặn I → **Slide 17–19**.
13. **Action boundary là gì, ép ngoài prompt thế nào?** 4 thành phần + 6 lớp (credential, gateway, oracle, budget, approval-hash, audit/kill switch) → **Slide 20, 23, Backup 4**.
14. **Approval của người có đủ không?** Chỉ khi có ngữ cảnh, khối lượng hợp lý, và đo được chất lượng; nếu không là *rubber stamp* → **Slide 11, 22**.

Nếu Bị Hỏi "Nhóm Có Tự Tin Không?"

Trả lời: "Tự tin về *những gì đã đo* (cơ chế RLHF/CAI, các con số trong paper), và *không* tự tin về những gì chưa đo (propensity ngoài môi trường thực nghiệm). Thiết kế ở Slide 21–23 được chọn để *không phụ thuộc* vào việc model có aligned hay không."

Backup: Guardrail Kỹ Thuật Liên Quan & Đường Mở Rộng

Những gì deck này không trình bày, và vì sao chúng vẫn quan trọng

Hướng	Ý tưởng cốt lõi	Liên hệ với deck
Indirect prompt injection (Greshake et al., 2023)	Nội dung retrieve/duyệt web chứa chỉ thị; model không phân biệt data với instruction	Là failure mode (B) của Slide 18; giảm thiểu bằng privilege separation (Slide 23)
Dual-LLM / privilege separation (Willison, 2023)	LLM "không tin cậy" chỉ sinh *đề xuất có cấu trúc*; LLM "đặc quyền" chỉ nhận lệnh đã kiểm	Chính là Lớp 2–3 ở Slide 23; là lý do drafter có credential `none` (Backup 4)
Classifier guardrails (Llama Guard; NeMo Guardrails)	Phân loại input/output theo policy trước/sau khi gọi model	Hữu ích như *một* lớp phát hiện, nhưng là *classifier* chứ không phải *boundary*: có false negative
Agentic injection benchmark (AgentDojo, Debenedetti et al., 2024)	Đo khả năng chống injection của agent trong môi trường tool thật	Đề xuất đưa vào *red-team suite* của CI (Backup 4)
Concrete Problems in AI Safety (Amodei et al., 2016)	Side effects, reward hacking, scalable oversight, safe exploration	Khung *thuật ngữ* cho toàn bộ seminar: "reward hacking" = CAI/RLHF; "safe exploration" = action boundary
Human-in/on-the-loop patterns	In-the-loop: chặn trước hành động; on-the-loop: giám sát + audit mẫu	C2 = in-the-loop; C0/C1 = on-the-loop (Slide 21–22)

Điều Nhóm Cố Tình Không Làm Trong Đồ Án

Nhóm **không** xây "alignment" mới và **không** claim hệ mình an toàn tuyệt đối. Nhóm chọn phần *kiểm chứng được*: (i) policy tất định + test tự động, (ii) oracle độc lập cho citation/hiệu lực, (iii) escalation fail-closed có hồ sơ. Ba thứ này *đo được* bằng test, không cần tin vào lời khai của model.